#### Estimering

#### Viktige estimatoregenskaper:

Estimatoren  $\hat{\Theta}$  bør være **forventningsrett**, DVS  $E(\hat{\Theta}) = \Theta$ , hyor  $\Theta$  er et parameter du prøver å estjemre. Variansen til Ô bør være synkende med økende antall observasjoner.

Om du har to estimatorer  $\hat{\Theta}_1$ ,  $\hat{\Theta}_2$  er estimatoren med minst varians den mest effektive estimatoren for Θ.

### Noen vanlige estimatorer, standardsituasjoner:

μ: For et tilfeldig utvalg av størrelse n fra en populasion med forventning  $\mu$  og varians  $\sigma^2$  er en estimator for  $\mu$  gitt ved:  $\bar{X} = \frac{1}{n} \sum_{i=1}^{n} X_i$   $E(\bar{X}) = \mu$   $Var(\bar{X}) = \frac{\sigma^2}{n}$ 

$$=\frac{1}{2}\sum_{i=1}^{n}X_{i}$$
  $E(\bar{X})=\mu$   $Var(\bar{X})=\frac{\sigma^{2}}{2}$ 

 $\sigma^2$ : For et tilfeldig utvalg av størrelse n fra en populasjon med forventning  $\mu$  og varians  $\sigma^2$  er en estimator for  $\sigma^2$ 

gift veu. 
$$S^2 = \prod_{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 E(S^2) = \sigma^2 \ Var(S^2) = \frac{2\sigma^4}{n-1}$$
  $p$ . For et tilfeldig utvalg av størrelse  $n$  fra et binomisk forsøk (Bernulli-forsøksrekke) med sannsynlighet  $p$ . En estimator for  $p$  er gitt ved

to p a grave 
$$E(\hat{p}) = p$$
  $Var(\hat{p}) = \frac{\varrho(1-\varrho)}{\mu_1 - \mu_2}$ ; For to uavhengige utvalg as storrelser  $n_1$ ,  $n_2$  fra populasjoner med forventning  $\mu_1$ ,  $\mu_2$  og varianser  $\sigma_1^2$ ,  $\sigma_2^2$  or en estimator for  $\mu_1 - \mu_2$  gift ved

$$\bar{X}_1 - \bar{X}_2 \; E(\bar{X}_1 - \bar{X}_2) = \mu_1 - \mu_2 \; Var(\bar{X}_1 - \bar{X}_2) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$$

$$\frac{\sigma_1^2}{2}$$
. For to tilfieldig utvalg av størrelser  $n_1$ ,  $n_2$  fra normalfordelte populasjoner med forventninger  $\mu_1$ ,  $\mu_2$  of varianser  $\sigma_1^2$ ,  $\sigma_2^2$  er en estimator for  $\frac{\sigma_1^2}{2}$  gitt ved:  $\frac{S_1^2}{2}$   $\rho_1-\rho_2$ : For to uavhengige utvalg fra binomiske forsøk med sannsynligheter  $\rho_1$ ,  $\rho_2$  er en estimator for  $\rho_1-\rho_2$  gitt ved:

 $\mu_D$ : For to parvise tilfeldig utvalg av størrlese n der differansene fra populasjonene med forventning  $\mu_D$  og varians  $\sigma_D^2$  er en estimator for  $\mu_D$  gitt ved:

$$\bar{D}$$
  $E(\bar{D}) = \mu_D$   $Var(\bar{D}) = \frac{\sigma_D^2}{n}$ 

## Utvalgsfordelinger

En utvalgsfordeling er fordelinga for en observator (funksion av de stokastiske variablene i utvalget) for et (tilfeldig) utvalg data. Vi er gierne interresert i fordelinga til (de spesielle observatorene som er ) estimatorer for paramerere i populasjonen, ofte på standarisert form.

#### Standardsituasjonene (Utvalgsfordelinger)

 $\bar{X}$ , Z: For et tilfeldig utvalg av størrelse n fra en normalfordelt populasjon med forventning  $\mu$  og varians  $\sigma^2$ 

vii:  $\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$   $Z = \frac{\bar{X} - E(\bar{X})}{\sqrt{Var(\bar{X})}} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$  SGT: Selv om populasjonen ikke er normalfordelt vil resultatet over gjelde når  $n \to \infty$ . Regner vanlighvis tilnærminga for god når  $n \ge 30$ 

T: For et tilfeldig utvalg av størrelser n fra en normalfordelt populasjon med forventning  $\mu$  og varians  $\sigma^2$ , der variansen estimeres ved  $S^2$  fra utvalget har vi at:

$$T = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} = \frac{\frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}}}{\sqrt{\frac{S^2}{\sigma^2}}} \sim t_{n-1}$$

 $S^2$ : For et tilfeldig utvalg av sørrelse n fra en normalfordelt

populasjon med forventning  $\mu$  og varians  $\sigma^2$ :  $\frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2_{n-1}$   $\hat{p}$ : For et tilfeldig utvalg av størrelse n fra et binomisk forsøk med sannsynlighet p har vi tilnærmet at:  $Z = \frac{\hat{p} - E(\hat{p})}{\sqrt{Var(\hat{p})}} = \frac{\hat{p} - p}{\sqrt{\frac{p(1 - p)}{1 - p}}} \sim N(0, 1)$ 

 $ar{X}_1 - ar{X}_2$ : For to uavhengige tilfeldig utvalg  $n_1$ ,  $n_2$  (normalfordelt) med forventning  $\mu_1$ ,  $\mu_2$  og varianser

$$X_1 - X_2$$
: For to uavhengige tilfeldig utvalg  $n_1$ ,  $n_2$  (normalfordelt) med forventning  $\mu_1$ ,  $\mu_2$  og varianser  $\sigma_1^2$ ,  $\sigma_2^2$  vil:

$$\sigma_1^2, \, \sigma_2^2$$
 vil:  $ar{X}_1 - ar{X}_2 \sim N\left(\mu_1 - \mu_2, \sqrt{rac{\sigma_1^2}{n_1} + rac{\sigma_2^2}{n_2}}
ight)$ 

$$Z = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{\sigma_1} + \frac{\sigma_2^2}{\sigma_2}}} \sim N(0, 1)$$

Gjelder også for tilnærma uten å forutsette normalfordelt  $(\text{stor } n_1 \text{ og } n_2)$ 

For ukjent men lik varians  $\sigma_1^2 = \sigma_2^2 = \sigma_n^2$  estimeres med  $S_n^2$ :

$$T = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{S_\rho \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim T_{n_1 + n_2 - 2}$$

For ukjent og ulik varians  $\sigma_1^2 \neq \sigma_2^2$ , estimeres med  $S_1^2, S_2^2$ 

$$T = \frac{(\hat{x}_1 - \hat{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\hat{x}_1^2}{\hat{x}_1^2} + \frac{\hat{x}_2^2}{\hat{x}_2^2}}} \sim T_{\nu} \quad \nu = \frac{\left(\frac{\hat{x}_1^2}{\hat{x}_1^2} + \frac{\hat{x}_2^2}{\hat{x}_2^2}\right)^2}{\left(\frac{\hat{x}_1^2}{\hat{x}_1^2} + \frac{\hat{x}_2^2}{\hat{x}_2^2}\right)^2}$$
F: For to undergoing tilled in a plane for

F: For to uavhengige tilfeldige utvalg  $n_1$ ,  $n_2$  (normalfordelt) med forventning  $\mu_1$ ,  $\mu_2$  og varianser  $\sigma_1^2$ ,  $\sigma_2^2$  har vi at:

$$F = \frac{\frac{S_1^2}{n_1}}{\frac{S_2^2}{n_2}} = \frac{S_1^2 \sigma_2^2}{S_2^2 \sigma_1^2} \sim F_{n_1 - 1, n_2 - 1}$$

 $\hat{p}_1 - \hat{\hat{p}}_2$ : med to tilfeldig utvalg  $n_1$ ,  $n_2$  (binomisk) med sannsynligheter  $p_1$ ,  $p_2$  har vi tilnærma at (om  $n_1$ ,  $n_2$  stor nok):  $Z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\frac{1}{2} n_1 (1 - p_1) \frac{p_2 (1 - p_2)}{p_2 (1 - p_2)}} \sim N(0, 1)$ 

$$Z = \frac{(\hat{p}_1 - \hat{p}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}} \sim N(0, 1)$$

 $\bar{\it D}$ : for to parvise tilfeldige utvalg av størrelse  $\it n$  der differansene er normalfordelte med forventning  $\mu_D$  og varians  $\sigma_D^2$  og der variansen estimeres ved  $S_D^2$  fra utvalget har vi at:

$$T = \frac{\tilde{D} - \mu_D}{\frac{S_D}{\sqrt{n}}} \sim t_{n-1}$$

#### Intervallestimering

Konfidensintervall for  $\mu$  (KI)

KI for 
$$\mu$$
 med kjent  $\sigma^2$ :  

$$P\left(-z_{\frac{\alpha}{2}} < \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} < z_{\frac{\alpha}{2}}\right) = 1 - \alpha$$

$$\Rightarrow \mu = \bar{X} \pm z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}$$

KI for  $\mu$  med  $S^2$  som estimator for ukjent  $\sigma^2$  med n-1frihetsgrader:  $P\left(-t_{\frac{\alpha}{2}}<\frac{\bar{X}-\mu}{\frac{s}{\sqrt{\alpha}}}< t_{\frac{\alpha}{2}}\right)=1-\alpha$  $\Rightarrow \mu = \bar{X} \pm t_{\frac{\alpha}{2}} \cdot \frac{s}{\sqrt{n}}$ 

## Konfidensintervall for $\sigma^2 \bmod n = 1$ (KI) $P\left(\mathcal{X}_{1-\frac{\alpha}{2}}^2\,<\,\frac{(n-1)S^2}{\sigma^2}\,<\,\mathcal{X}_{\frac{\alpha}{2}}^2\, ight)$ $\Rightarrow \sigma^2 \in \left[\frac{(n-1)S^2}{\chi^2_{\underline{\alpha}}}, \frac{(n-1)S^2}{\chi^2_{1-\underline{\alpha}}}\right]$

#### Konfidensintervall for $\rho$

KI for p med utvalg av størrelse n fra et binomisk forsøk med sannsynlighet p (OBS: n > 30 /stor nok)  $P\left(-z_{\frac{\alpha}{2}} < \frac{\hat{p}-p}{\sqrt{\frac{p(1-p)}{p}}} < z_{\frac{\alpha}{2}}\right) = 1 - \alpha$  $\Rightarrow p = \hat{p} \pm z_{\frac{n}{2}} \sqrt{\frac{p(1-p)}{p}}$  Erstatt p i utrykket med  $\hat{p}$  for å kunne regne ut

### Konfidensintervall for $\mu_1-\mu_2$

For to uavhengige tilfelig utvalgte utvalg av størrelser  $n_1$  og  $n_2$  fra normalfordelte populasjoner med forventning  $\mu_1$ ,  $\mu_2$  og vareanser  $\sigma_1^2$ ,  $\sigma_2^2$ :

For **kjente** vareanser 
$$\sigma_1^2$$
,  $\sigma_2^2$ :

$$\begin{array}{ll} \mu_1 \ - \ \mu_2 \ = \ (\bar{x}_1 \ - \ \bar{x}_2) \ \pm \ z_{\frac{n}{2}} \ \sqrt{\frac{\sigma_1^2}{n_1}} \ + \ \frac{\sigma_2^2}{n_2} \ = \ 1 \ - \ \alpha \end{array}$$
 For **ukjente men like** vareanser  $\sigma_1^2 \ = \ \sigma_2^2$  med antall frihetsgrader  $\nu \ = \ n_1 \ + \ n_2 \ - \ 2$ :

For **ukjente men** linke vareanser  $\sigma_1^- = \sigma_2^-$  med antali frihetsgrader  $\nu = n_1 + n_2 - 2$ :  $\mu_1 - \mu_2 = (\bar{s}_1 - \bar{s}_2) \pm s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} = 1 - \alpha$  For **ukjente men ulike** vareanser  $\sigma_1^+ \neq \sigma_2^2$  der antall frihetsgrader  $\nu$  er gitt fra utvalgsfordelinga:

$$\mu_1 - \mu_2 = (\bar{x}_1 - \bar{x}_2) \pm t_{\frac{\alpha}{2}} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}} = 1 - \alpha$$

## Konfidensintervall for $\frac{\sigma_1^2}{\sigma_2^2}$

$$\begin{split} \text{Normalfordelt, med } & \mu_1, \ \mu_2 \text{ og } \sigma_1^2, \ \sigma_2^2 \colon \\ & P\left(f_{1-\frac{\alpha}{2}, \nu_1, \nu_2} < \frac{S_2^2 \sigma_1^2}{S_2^2 \sigma_1^2} < f_{\frac{\alpha}{2}, \nu_1, \nu_2} \right) \\ & \Rightarrow \frac{\sigma_1^2}{\sigma_2^2} \in \left[\frac{S_1^4}{S_2^2} \frac{1}{I_{\frac{\alpha}{2}, \nu_1, \nu_2}}, \frac{S_1^8}{S_2^8} f_{\frac{\alpha}{2}, \nu_1, \nu_2} \right] \end{split}$$

# Konfidensintervall for $p_1-p_2$ Uavhengig tilfeldig utvalg $n_1$ , $n_2$ fra binomisk forsøk med

sannsynlighet 
$$p_1$$
,  $p_2$  har vi (om  $n_1$ ,  $n_2$  store nok): 
$$(\hat{p}_1 - \hat{p}_2) \pm z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}} = 1 - \alpha$$

normalfordelte differanse med forventning  $\mu_{\mathrm{D}}$  og varians  $\sigma_D^2$  (Variansen estimeres med  $S_D^2$ )  $\bar{d} \pm t_{\frac{\alpha}{2}} \frac{S_D}{\sqrt{n}} = 1 - \alpha$ 

regne ut hva lengden vil bli for et gitt valg av n og  $\alpha$ =  $2 \cdot z_{\frac{\alpha}{2}} \cdot SE(\hat{\Theta})$ , to typiske tilfeller:

Konstruere KI for  $\mu$  basert på estimatoren:  $\bar{X}$  blir lengda:

$$L=2\cdot z_{\frac{\alpha}{2}}\cdot \frac{\sigma}{\sqrt{n}} \Rightarrow n=\left(\frac{2z_{\frac{\alpha}{2}}\sigma}{L}\right)^2$$
  
Når  $\sigma^2$  må estiemres kan vi finne approx forventa lengde

2. Når vi konstruerer KI for p basert på and who is the deferming  $\hat{p}$  ( $l \approx L$ ):  $L = 2 \cdot z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{l}} \le \frac{z_{\frac{\alpha}{2}}}{\sqrt{n}} \Rightarrow n = 1$  $\left(\frac{2z_{\frac{\alpha}{2}}\sqrt{\hat{p}(1-\hat{p})}}{I}\right)^{\frac{1}{2}}$ 

## Estimeringsfeil

Når fordelinga til estimatoren er kjent (utvalgsfordelinga) kan vi regne ut hvor stor feil vi giør i estimeringa. Vil ofte ha en viss sannsynlighet for at feilen ikke skal overskride en verdi e  $P(|\hat{\Theta} - \Theta| < e = 1 - \alpha)$  (vanlige tilfeller)

$$P(|\bar{X} - \mu| < e = 1 - \alpha) \Rightarrow n = \left(\frac{z_{\frac{\alpha}{e}}\sigma}{e}\right)^2 \Rightarrow e = z_{\frac{\alpha}{e}}\frac{\sigma}{\sqrt{n}}\hat{p}$$
 (binomisk):

$$P(|\hat{p} - p| < e = 1 - \alpha) \Rightarrow n \approx \left(\frac{z_{\frac{n}{2}}\sqrt{\hat{p}(1-\hat{p})}}{e}\right)^2 \Rightarrow e \approx z_{\frac{n}{2}}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

### Noen regneregler

$$\begin{aligned} &(u \cdot v)' = u'v + u \cdot v' \\ &(\frac{u}{v}) = \frac{u'v - u \cdot v}{v} \\ &\int \ln(x) \, dx = x \ln(x) - x + C \\ &u \text{ er et utrykk med } x \\ &\int \frac{u}{u} \, dx - \frac{u''}{v \cdot \ln(a)} + C \\ &\int \frac{1}{u} = \frac{\ln(x)}{u} + C \\ &\int u \cdot v' \, dx = u \cdot v - \int u'v \, dx \end{aligned}$$

$$\begin{array}{l} E(X) \text{ og } Var(X) \\ Var(aX+bY) = a^2 Var(X) + b^2 Var(Y) \\ E(\chi^2_{n-1}) = n-1 \\ E(T_\nu) = 0 \\ Var(T_\nu) = \frac{\nu}{\nu-2}, \quad \nu \geq 3 \end{array}$$

### Prediksjonintervall

Et intervall som sier noe om neste verdi  $X_0$  i en normalfordelt populasjon:  $X \sim N(\mu, \sigma)$ 

**Kjent** 
$$\mu$$
 **og**  $\sigma$  (spredningsintervall)
$$P\left(\mu - z_{\frac{\alpha}{2}} \cdot \sigma < X_0 < \mu + z_{\frac{\alpha}{2}} \cdot \sigma\right) = 1 - \alpha$$

 $\Rightarrow X_0 = \mu^2 \pm z_{\frac{\alpha}{2}} \cdot \sigma$ Ukjent  $\mu$ , kjent  $\sigma$ 

Ukjent 
$$\mu$$
,  $\sigma$  frihetsgrad  $\nu = n - 1$ 

$$X_0 = \bar{x} \pm z_{\frac{\alpha}{2}} \cdot S\sqrt{1 + \frac{1}{n}}$$

Formel for  $S_p^2$  (Gjelder for alt på arket)  $S_P^2 = \frac{S_1(n_1-1)+S_2^2(n_2-1)}{n_1+n_2-2}$ 

### Fordelinger

## Binomisk fordeling

- n uavhengige delforsøk
- To utfall: suksess/ikke suksess Samme sannsynlighet for p = P(a) (suksess) i alle

#### delforsøk Hypergeometrisk fordeling

Populasjon med N elementer

- k av disse regnes som "suksess". N k som "fiasko"
- 3. Trekker *n* elementer uten tilbakelegging Sannsynligheten *p* endrer seg mellom hvert delforsøk.
- Negativ binomisk fordeling

Antall forsøk du må gjøre for at hendelsen A (suksess) skal intreffe k ganger

#### Geometrisk fordeling

Antall forsøk du må gjøre for at hendelsen A (suksess) skal intreffeførste gang

### Poisson-fordeling

 $\mu = \lambda t$ ,  $\sigma^2 = Var(X) = \lambda t$   $f(X) = \frac{\mu^x}{2} e^{-X}$ 

. Antallet av A disjunkte tidsintervall er uavhengige . Forventa antall av A er konstant list  $\lambda$  (raten) per tidsenhet

3 Kan ikke få to forekomster samtidig

## Gammafordeling

En kontinuerlig vareabel X er gammafordelt med parameter  $\alpha>0$  og  $\beta>0$  dersom tetthetsfunksjonen er gitt ved (se blå tabell). Ventetida til hendelse nummer k i en Poisson-prosess vil være gammafordelt med  $\alpha = k$  og

Eksponensialfordeling
Ventetida til første hendelse (og mellom etterfølgende handelser) i en Poisson-prosess følger en eksponensialfordeling. En kontinuerlig variabel X har eksponentialfordeling med parameter  $\beta>0$  dersom tetthetsfunksjonen er gitt ved (se tabellbok: f(x)). Eksponensialfordelinga er en variant av gammafordelinga  $med \alpha = 1$ 

## Stokastisk variabel

### En variabel

En variabel 
$$\mu = E(X) = \begin{cases} \sum_x x \cdot f(x), & \text{deskret} \\ \int_{-\infty}^{\infty} x \cdot f(x) dx, & \text{kontinuerlig} \end{cases}$$
 
$$\sigma^2 = Var(X) = \begin{cases} \sum_x (x - \mu)^2 f(x), & \text{deskret} \\ \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx, & \text{kontinuerlig} \end{cases}$$
 
$$F(X) = \int_0^x f(t) dt$$
 Funksjoner av stokastiske variabler

Funksjoner av stokastiske variabler 
$$\mu_{g(X)} = E(g(X)) = \begin{cases} \sum_{x} g(x) \cdot f(x), & \text{deskret} \\ \int_{-\infty}^{\infty} g(x) \cdot f(x) dx, & \text{kontinuerlig} \end{cases}$$

$$\sigma^{2} = Var(g(X)) = 0$$

deskret

$$\begin{split} \sigma_{g(X)}^2 &= \textit{Var}(g(X)) = \\ \sum_{X} (g(x) - \mu_{g(X)})^2 \cdot f(x), & \text{deskret} \\ \int_{-\infty}^{\infty} (g(x) - \mu_{g(X)})^2 \cdot f(x) dx, & \text{kontinuerlig} \\ \mu_{g(X,Y)} &= E(g(X,Y)) = \end{split}$$

$$\begin{cases} \sum_X \sum_X g(x,y) f(x,y), & \text{deskret} \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x,y) f(x,y) \, dx \, dy & \text{kontinuerlig} \\ \text{Simultanfordeling for to variabler} \end{cases}$$

$$P(X, Y) = \begin{cases} \sum \sum f(x, y), & \text{deskret} \\ \int \int f(x, y) \, dx \, dy, & \text{kontinuerlig} \end{cases}$$

# Marginale fordelinger (to variabler)

$$g(x) = \begin{cases} \sum_{y} f(x, y) \\ \int_{-\infty}^{\infty} f(x, y) \, dy \end{cases}$$
$$h(y) = \begin{cases} \sum_{x} f(x, y) \\ \int_{-\infty}^{\infty} f(x, y) \, dx \end{cases}$$

 $h(y) = \begin{cases} \sum_{x} f(x, y) \\ \int_{-\infty}^{\infty} f(x, y) dx \end{cases}$  **Betinga fordeling** (for Y gitt X)  $f(y|x) = \frac{f(x, y)}{g(x)}, \quad g(x) > 0$ 

#### Kovarians $\sigma_{XY} = Cov(X, Y) =$

$$\begin{cases} \sum_{x} \sum_{y} (x - \mu_{X})(y - \mu_{Y}) f(x, y) \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_{X})(y - \mu_{Y}) f(x, y) dx dy \\ \text{Korrelasjon:} \\ \rho_{XY} = \frac{Cov(X, Y)}{\sqrt{Paf(Y) \cdot Paf(Y)}}, \qquad -1 < \rho_{XY} < 1 \end{cases}$$

### Sannsynlighetsregler

Addisjonsregelen:  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ Multiplikasjonsregelen:  $P(A \cap B) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$ Betinga sannsynlighet:  $P(A|B) = \frac{P(A \cap B)}{P(B)}$ 

Bettings same spaces. Total sansaynlighet:  $P(A) = \sum_{i=1}^n P(B_i \cap A) = \sum_{i=1}^k P(B_i) \cdot P(A|B_i)$  Bayes setning:  $P(B|A) = \frac{P(B) \cdot P(A|B)}{P(A)}$ 

Tilfeller ved uavhengighet:  $P(A \cap B) = P(A) \cdot P(B)$  P(A|B) = A(A)

### Testina

Lager tester som tar stilling til påstander. Har da: nullhypotesen  $(H_0)$  og en utfordrende hypotese  $(H_1)$ . Vi bruker testobservatorer for å kunne si nø om Ho er sann eller ikke.

## Normalfordelt estimator:

Dersom vi har en normalfordelt forventningsrett estimator  $\hat{\Theta}$  for parameter  $\Theta$ :  $\hat{\Theta} \sim N(\Theta, SE(\hat{\Theta}))$ 

Kan vi konstruere testobservator  $Z = \frac{\Theta - \Theta}{\Theta = 0}$ 

(Måler hvor mange standardavvik  $\hat{\Theta}$  er fra  $\Theta_0$ .) -Om  $H_0$  er sann vil Z bli standardnormalfordelt -Om  $H_1$  er sann vil vi forvente at  $\hat{\Theta}$  blir større enn  $\Theta_0$ , og

dermed at Z blir stor. Forkastningsområdet velges slik at med sannsynlighet  $\alpha$ for å få en så stor verdi, dersom  $H_0$  er sann. Kritisk verdi blir da  $z_{\alpha}$  om  $Z>z_{\alpha}$ 

#### P-verdi:

Som et alternativ fil å finne et forkastningsområde for Z kan man finne en p-verdi som er det minste signifikansnivået som ville forkastet nullhypotesen.

Feil av type I/II: P(Feil av type I) = P(Forkaste en rett  $H_0$ )= $\alpha$ 

P(Feil av type II) = P(ikke forkaste gal  $H_0$ )= $\beta$ Det ideelle er å få  $\alpha$  og  $\beta$  minst mulig.  $1 - \beta$  kalles for styrken til en test og sier hvor sannsynlig

det er å forkaste Ho som funskjon av den sanne parameterverdien. Ved å finne denne for ulike verdier av parameteren akn vi skissere en styrkefunksjon.

parameteren and vi skissere en styrkerunksjon. **Ulike hypoteseoppsett:** Om vi har  $H_0 \Rightarrow \hat{\Theta} = \Theta_0$  har vi tre tester. Venstresidig, tosidig og høyresidig.  $H_1$  blir da respektivt:  $\hat{\Theta} < \Theta_0 \quad \hat{\Theta} \neq \Theta_0 \quad \hat{\Theta} > \Theta_0$  Hvis ikke en retning er indikert er en tosidig test å festertelke.

Noen vanlige tester, standardsituasjoner  $\mu$ : fra normalfordelt utvalg av størrelse n, kjent  $\sigma^2$ .

Testobservator blir da (for alle testene):  $Z = \frac{\bar{X} - \mu_0}{\sigma}$ 

Som forkaster når (VS Tosidig HS)

 $z<-z_{\alpha} \quad |z|>z_{\frac{n}{2}}\quad z>z_{\alpha}$   $\mu$ : fra normalfordelt utvalg av størrelse n, ukjent  $\sigma^2$ , bruker  $S^2$ . Testobservator vil bli  $t-fordelt \bmod n-1$ firhetsgrader

Testobservator blir da (for alle testene):  $t=rac{ar{x}-\mu_0}{s_{\parallel}}$  Som

forkaster når (VS Tosidig HS)  $t<-t_{lpha} \qquad |t|>t_{rac{lpha}{2}} \qquad t>t_{lpha}$ 

 $\sigma^2$ : fra normalfordelt utvalg av størrelse n. Testobservator vil bli *kjikvadratfordelt*  $(\chi^2)$  med n-1 frihetsgrader.

Testobservator for alle testene:  $\chi^2 = \frac{(n-1)S^2}{\sigma_n^2}$ Som forkastes når: (VS Tosidig HS)

Som forkastes nâr: (VS Tosidig HS) 
$$\chi^2 < -\chi^2_{1-\alpha} \qquad \chi^2 < \chi^2_{1-\frac{\alpha}{2}} \lor \chi^2 > \chi^2_{\frac{\alpha}{2}}$$
 
$$\chi^2 > \chi^2_{\alpha}$$

p for et tilfeldig utvalg av størrelse n fra et binomisk forsøk med sannsynlighet p. Hvis n stor nok ( $n \geq 30$ ) kan tilnærmes normalfordelt. Testobservator blir da:  $Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)}}$ , grenser = grensene

Hvis n < 30 må man bruke binomisk fordeling, vanlig testobservator er da X = antall suksesser. Vanlig å bruke **p-verdi** for dette tilfellet.

varing a bruke **prevent** for dette time.  $\mu_1 - \mu_2$ : For to uavhengige utvalg av størrelser  $n_1$ ,  $n_2$  (normalfordelt) med forventninger  $\mu_1$ ,  $\mu_2$  og varianser  $\sigma_1^2,\,\sigma_2^2.$  Dette gir  $H_0\colon \mu_1-\mu_2=d_0$  (en vanlig test er  $d_0=0$ )

**Kjent varians**  $\sigma_1^2$ ,  $\sigma_2^2$ : Testobservatoren blir da  $Z = \frac{(\bar{x}_1 - \bar{x}_2) - c_0}{\sqrt{\frac{\sigma_1^2}{r_0^4} + \frac{\sigma_2^2}{r_0^2}}} \text{ forkasningsgrensene blir som en vanlig Z}$  test  $(\mu \text{ med ukjent } \sigma^2)$ 

Forkastningsgrensene blir som en vanlig  ${\mathcal T}$  test ( $\mu$  med ukient  $\sigma^2$ )

ukjent og ulik varians  $\sigma_1^2 \neq \sigma_2^2$ : Testobservatoren blir *t-fordelt* med frihetsgrad gitt fra utvalgsfordelinga. Testobservator blir da:  $T = \frac{(\bar{X}_1 - \bar{X}_2) - 1}{\sqrt{\frac{S_1^2}{2} + \frac{S_2^2}{2}}}$ 

 $\frac{\sigma_1^2}{\sigma_2^2}$ : for to uavhengige utvalg av størrelser  $n_1$ ,  $n_2$  $\sigma_1^2$  (normalfordelt) med forventninger  $\mu_1$ ,  $\mu_2$  og varianser  $\sigma_1^2$ ,  $\sigma_2^2$ . Testobservatoren blir da *f-fordelt* med firhetsgrader  $n_1-1$  og  $n_2-1$ . Testobservatoren blir da (for alle testene):  $F=\frac{S_1^2}{S_2^2}$  som forkastes når

(VS Tosidig HS)  $F < \frac{1}{F_{\alpha,\nu_1,\nu_2}}$   $F_{\frac{\alpha}{2},\nu_1,\nu_2} < F < \frac{1}{F_{\frac{\alpha}{2},\nu_1,\nu_2}}$ 

 $F > F_{\alpha_1\nu_1,\nu_2}$   $\rho_1 - \rho_2 \colon \text{For to uavhengige tilfeldige utvalg av størrelse}$   $n_1, n_2 \text{ (binomisk)} \text{ med sannsynligheter } \rho_1, \rho_2 \colon \text{Får}$  $H_0: p_1-p_2=d_0$ . Testobservator blir

 $\frac{\frac{\hat{p}_{1}(1-\hat{p}_{1})}{n_{1}} + \frac{\hat{p}_{2}(1-\hat{p}_{2})}{n_{2}}}{n_{2}}$ Hvis  $d_0=0$ :  $\frac{\hat{\rho}_1-\hat{\rho}_2}{\sqrt{p(1-p)}\left(\frac{1}{n_1}+\frac{1}{n_2}\right)}$  Standardnormalfordelt ved

stor nok  $n_1$ ,  $n_2$ . Forkastningsgrense blir som en vanlig Z test ( $\mu$  med kjent  $\sigma^2$ )  $\mu_D$ : Differansene er normalfordelt, variansen  $\sigma_D^2$  må

estimeres  $\mathcal{S}_{\mathcal{D}}^2$ . Får hypotesen  $\mathcal{H}_0: \mu_{\mathcal{D}} = \mathit{d}_0$ Testobservatoren er t-fordelt med n-1 firhetsgrader.

Testobservatoren blir da:  $T = \frac{\bar{D} - d_0}{\frac{S_D}{A}}$ . Forkastningsområdet blir deretter som en vanlig T-test.

## Styrkefunksjon

Ved å finne sannsynligheten for å forkaste  $H_0$  for ulike verdier av parameteren,  $\Theta$ , finner vi styrkefunksjonen:

$$\begin{array}{ll} 1-\beta(\Theta)=P(\text{Forkaste }H_0,\,\text{sann verdi}=\Theta) \\ 1-\beta(\mu)=1-\Phi\left(z_\alpha-\frac{\mu-\mu_0}{\frac{\sigma}{\gamma_0}}\right) & n=\frac{(z_\alpha-z_\beta)^2\sigma^2}{(\mu-\mu_0)} \end{array}$$

#### Kombinatorikk

### Multiplikasjonsregelen

Forsøk i k etapper, med  $m_1$ ,  $m_2$  · · · ,  $m_k$  mulige utfall i etappene. Totalt antall utfall:  $\prod_{i=1}^{k} m_i$ 

#### Potensregelen

n merka enheter, velger k med tilbakelegging. Antall ordna utfall:  $n^k$ Permutasjonsregelen (nPr)

n merka enheter, velger k uten tilbakelegging, antall ordna utfall:

# ${}_{n}P_{r}=rac{n!}{(n-k)!}$ Kombinasjonsregelen

 $\emph{n}$  merka enheter, velger  $\emph{k}$  uten tilbakelegging, antall ikke-ordna utfall:

$$_{n}C_{r} = \binom{n}{k} = \frac{n!}{(n-k)!k!}$$

Forenklinger for lineærkombinasjoner  $Var(aX+bY)=a^2Var(X)+b^2Var(Y)+2ab\cdot Cov(X,Y)$  Merk: hvis X og Y er uavhengige er Cov(X,Y)=0 E(aX+b)=aE(X)+b Tsjebysjeffs teorem: Sannsynligheten for at verdien på en variabel X ligger

innafor k avstander fra forventningsverdien er minst 1  $-\frac{1}{k^2}$ Sannsynlighetsmaksimeringsfunksjonen:

$$L(\Theta) = \prod_{i=1}^{n} f(x_i, \Theta)$$
  
Løses ved å:

1. Ta algoritmen av funksjonen

$$\ln\left(\frac{a}{b}\right) = \ln(a) - \ln(b), \qquad \ln(ab) = \ln(a) + \ln(b)$$

2. Deriver utrykker med hensyn på variabelen 
$$\Theta$$
 oftest  $\beta$  3. Sett utrykket lik 0 og løs med hensyn på variabelen.

#### Tilfeldig utvalg:

Når et utvalg er tilfeldig, kan vi se på det som en mengde identiske og uavhengige observasjoner.

#### QQ-plot:

- Plotter utvalgskvantiler (Observasjonene ordna etter størrelse) mot teoretiske kvantiler ("Ideelle observasjoner") fra aktuell fordeling
- Teoretiske kvantiler er gitt ver invers kumulativ fordeling "jevnt spredte"
- sannsynligheter mellom 0 og 1 Om antatt fordeling stemmer skal plotter gi en tilnerma rett linje x = y

### Enkel linær regresjon

Har observasjonspar  $(x_1, y_1), \ldots, (x_n, y_n)$ 

Regresjonsmodellen

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i,$$
  $i = 1, \ldots, n$ 

Forutsetningene er at

$$E(\epsilon_i) = 0,$$
  $Var(\epsilon_i) = \sigma^2,$   $i = 1, ..., n$ 

og  $\epsilon_1,\,\ldots,\,\epsilon_n$  er inbyrdes uavhengige. Dette medfører at

$$\textit{E}(\textit{Y}_i) = \mu_{\textit{Y}|\textit{x}_i} = \beta_0 + \beta_1 \textit{x}_i, \hspace{0.5cm} \textit{Var}(\textit{Y}_i) = \sigma^2_{\textit{Y}|\textit{x}_i} = \sigma^2, \hspace{0.5cm} \textit{i} = 1, \ldots, \textit{n}$$

der  $Y_1, \ldots, Y_n$  også er innbyrdes uavhengige.

Bruker miste kvadrat-metoden til å estimere  $\beta_0$  og  $\beta_1$  fra data for å få ei estimert (tilpassa) regresjonslinje for forventningslinja  $\beta_0+\beta_1x$ :

$$\hat{y} = b_0 + b_1 x$$

MKM baserer seg på å minimere

$$SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2$$

$$B_1 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(Y_i - \overline{Y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2} = \frac{\sum_{i=1}^{n} (x_i - \bar{x})Y_i}{\sum_{i=1}^{n} (x_i - \bar{x})^2}, B_0 = \overline{Y} - B_1 \overline{x}$$

$$E(B_1) = \beta_1,$$
  $Var(B_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \overline{x})^2}$ 

$$E(B_0) = \beta_0,$$
  $Var(B_0) = \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \overline{x})^2}$ 

I tillegg har vi (forventningsrett) estimator for  $\sigma^2$ :

$$S^{2} = \frac{SSE}{n-2} = \frac{\sum_{i=1}^{n} (Y_{i} - \hat{Y}_{i})^{2}}{n-2} = \frac{\sum_{i=1}^{n} (Y_{i} - B_{0} - B_{1}x_{i})^{2}}{n-2}$$

## Parameterinferens

Om vi anntar at feilledda er normalfordelte

### Løningsforslag

Oppgave Ola samler spillekort. Ønsker et spesifikt spillekort (A). X er anntall kort han kjøper før han får dette. Det er 10 forskjellige spillekort i serien. Han kjøper pakker av kort med n = 20 kort i hver pakke. Hver pakke er uavhengig. Hva er fordelinga for antall kort i pakka som er med spiller A? Hva er sannsynligheten for at Ola får minst ett kort med spiller A i pakka?

Hva er forventa antall ulike spillekort i pakka? Ola gjør n=20 kjøp. Resultatet av hvert kjøp er uavhengige, og sannsynligheten for suksess (kort A) er lik  $\frac{1}{10}$  for hvert kjøp. Da blir Y= tall på kort A, binomisk fordelt med n=20 delforsøk og sannsynlighet  $p=\frac{1}{10}$ :

$$Y \sim \text{binom}\left(n = 20, p = \frac{1}{10}\right)$$
  
 $P(Y \ge 1) = 1 - P(X = 0) = 1 - \binom{20}{0} \left(\frac{1}{10}\right)^0 \left(1 - \frac{1}{10}\right)^{20} =$ 

1-0.122=0.878Definerer korttypene  $i\in\{A,B,\cdots,J\}$ :

$$I_i = \begin{cases} 1, & \text{minst ett kort av typen } i. \\ 0, & \text{ingen kort av typen } i \end{cases}$$

Da blir 
$$E(l_i) = 1 \cdot P(l_i = 1) + 0 \cdot P(l_i = 0) = P(l_i = 1) = P(Y \ge 1) = 0.878$$
 La tallet på ulike kort være  $N = \sum_i l_i$ . Da blir  $E(N) = E(\sum_i l_i) = \sum_i E(l_i) = \sum_i 0.878 = 10 \cdot 0.878 = 8.78$ 

Oppgave
Fordelinga til en kontinuerlig stokastisk variabel X er gitt ved følgende sannsynlighetstetthetsfunksjon:

$$f(x) = \begin{cases} \frac{2}{9}x, & 0 < x < 3\\ 0, & ellers \end{cases}$$

Vi er interresert i følgende hendelser:

$$X = \{X > 1\}$$
 og  $B = \{X > 2\}$ 

er disse hendelsene disjunkte?

Hva er sannsynligheten for B? Hva er sannsynligheten for B gitt A?

Er disse hendelsene uavhengige? Nei, A og B er ikke disjunkte, det er mulig at X>1 sammtidig som X>2

$$P(B) = P(X > 2) = \int_{2}^{3} f(x) dx = \int_{2}^{3} \frac{2}{9} x dx \left[ \frac{1}{9} x^{2} \right]_{2}^{3} = 1 - \frac{4}{9} = \frac{5}{9}$$

$$P(B|A) = \frac{P(B \cap A)}{P(A)} = \frac{P(A|B)P(B)}{P(A)} = \frac{1 \cdot P(B)}{P(A)} = \frac{\frac{5}{9}}{\int_{\frac{1}{9}}^{3} \frac{1}{9} x \, dx} = \frac{5}{8}$$

Vi ser at  $P(B|A) \neq P(B)$ , så A og B er ikke uavhengige

Oppgave

Vi skal se på rekkevidde for en elektrisk bilmodell (kjørelengde fra betteriet er fullt til tomt). Det blir påståt at bilprodusenter oppgir urealistisk lang rekkevidde, derfor lar vi n = 15 tilfeldig valgte sjåfører bruke bilen til normal kjøring til batteriet er tomt, for hver sjåfør er kjørelengda (km) registrert. Vi går ut ifra at disse kjørelengdene er et tillfeldig utvalg fra en populasjon med forventning  $\mu$  ( $\hat{\mu}=201.0667$ ) og varians  $\sigma^2$  ( $\hat{\sigma}^2=111.0667$ ). Produsenten av bilmodellen påstår er forventa rekkevidde er under

tilsvarende forhold 210 (km). Vi vil undersøke om det er grunnlag for å påstå at en reell rekkevidde er lavere enn dette. Sett opp hypoteser og testobservator, og utfør en test for problemstillinga over med signifikansnivå 5%.

Finn både forkastningsområde og (tilnærma) p-verdi. Hva blir konklusjonen? Vi går ut ifra at observatorene i et tilfeldig utvalg  $X_1,\ldots,X_{15}$  fra en normalfordelt populasjon med forventning  $\mu$  og standardavvik  $\sigma$ . Vi vil teste

$$H_0: \mu = 210$$
  $H_1: \mu < 210$ 

Ettersom  $\sigma$  er ukjent og maa estimeres fra data ved S blir dette en T-test,

$$T = \frac{\overline{X} - \mu_0}{\frac{s}{\sqrt{n}}}$$

som er *t-fordelt* med 
$$n-1=14$$
 firhetsgrader når  $H_0$  er sann. Insett data: 
$$t=\frac{201.067-210}{\frac{10.539}{\sqrt{\hbar}}}=-3.282$$

Forkaster  $H_0$  om  $t < t_{0.02,14} = -1.761$ . Så  $H_0$  blir forkasta, og vi kan påstå at forventnia rekkevidde  $\mu$  er under 210km. Kan finne p-verdien fra:

p-verdi = 
$$P(T_{14} < -3.282) = \begin{cases} < 0.005 \\ > 0.001 \end{cases}$$

Så fra tabellen kan vi se at p-verdien er mellom 0.1% og 0.5%. Da dette er lavere enn signifikansnivået på 0.5% blir H<sub>0</sub> forkasta.

Vi er og interresert i hvor mve rekkevidda kan variere.

Utled et 90%-konfidensintervall for variansen  $\sigma^2$ . Finn intervallestimatet fra observatorene. Hva kan du konkludere fra intervallet?

Withder et 90%-konfidensintervall fra variansen,  $\sigma^2$ , bruker at vi kjenner fordelinga for den standariserte observatoren

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$
 
$$P\left(\chi_{0.95}^2 < \frac{(n-1)S^2}{\sigma^2} < \chi_{0.05}^2\right) = 0.90$$
 
$$P\left(\frac{\chi_{0.95}^2}{(n-1)S^2} < \frac{1}{\sigma^2} < \frac{\chi_{0.05}^2}{(n-1)S^2}\right) = 0.90$$
 
$$P\left(\frac{(n-1)S^2}{\chi_{0.05}^2} < \sigma^2 < \frac{(n-1)S^2}{\chi_{0.95}^2}\right) = 0.90$$

$$\left(\frac{(n-1) \cdot s^2}{\chi_{0.05}^2}, \frac{(n-1) \cdot s^2}{\chi_{0.05}^2}\right) = \left(\frac{(15-1) \cdot 111.067}{23.685}, \frac{(15-1) \cdot 111.067}{6.571}, \frac{(15-1) \cdot 111.067}{6.571}\right)$$

Med 90% sannsynlighet for at intervallet inneholder den sanne verdien for variansen  $\sigma^2$ . Merk at fra dette kan vi og lage et 90%-konfidensintervall for standardavviket  $\sigma$ :

$$(\sqrt{65.65}, \sqrt{236.65}) = (8.10, 15.38)$$

Deloppqave  $Vi\ ønsker\ og\ å\ sammenligne\ modellem\ med\ en\ annen\ bilmodemm.\ Vi\ lar\ ei\ anna\ grupe\ <math>n_2=15\ sjálforer\ bruke\ denne\ andre\ modellen.\ Resultater:\ <math>\hat{\mu}=184.467,\ \hat{\sigma}^2=115.124.\ Vi\ går\ ut\ ifra\ at\ variansen\ for\ rekkevide er\ lik\ for\ de\ to\ ut\lag{ut\lagrange} up\ to\ et\ stimert$  Ger de nodvendige forutsetningene for\ de\ to\ utvalga,\ og\ regn\ ut\ et\ estimert

Solve the theoretic process of the state of samme for de to populasjonene. Et 95%-konfidensintervall for  $\mu_1-\mu_2$  er da gitt ved

$$\left(\overline{X}_1 - \overline{X}_2 - t_{0.025} \cdot S_p \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, \overline{X}_1 - \overline{X}_2 + t_{0.025} \cdot S_p \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}\right)$$
 Estimatet for den felles variansen blir

$$s_p^2 = \frac{s_1^2 \cdot (n_1-1) + s_2^2 \cdot (n_2-1)}{n_1 + n_2 - 2} = \frac{111.067 \cdot 14 + 115.124 \cdot 14}{15 + 15 - 2}$$
 Dermed blir intervallestimatet med insatte observasjoner:

 $201.067 - 194.467 \pm 2.048 \cdot \sqrt{113.095} \cdot \sqrt{\frac{1}{15} + \frac{1}{15}} = (-1.353, 14.553)$ Her or det having Her er det brukt  $n_1 + n_2 - 2 = 28$  frihetsgradet i t-fordelinga Vi kan med 95% sannsynlighet konkludre at den sanne forventa rekkeviddedifferansen ligger innenfor intervallgrensene. Da 0 er innafor intervallet vet vi og at en tosidig test (5% signifikansnivå) ikke ville forkasta  $H_0$ om ingen forskiell, kan ikke konkludere at forventa rekkevidde er ulike.